


E-commerce | Análise de Reviews de Clientes
Brasileiros

PROMPT TOOLKIT — CP02

P R O M P T E N G I N E E R I N G &
A R T I F I C I A L I N T E L L I G E N C E . F I A P

Wendel Pedro - Rm: 573126
Beatriz Araújo - rm: 570619
Daniel alejandro - RM: 573075
Victor Hugo Lavaqui - RM: 573838
Arthur Araujo Massarioli - RM: 573308
Anna Karla Rorato Albino - RM: 569604

ARQUITETURA — PIPELINE COMPLETO



INPUT

Input do Usuário → Guardrail de Entrada (Pydantic valida dados de entrada)

CHAIN 3 ETAPAS

- Etapa 1: Montagem do Prompt (prompt_builder.py)
- Etapa 2: Envio ao LLM via Ollama (llm_client.py)
- Etapa 3: Avaliação da Resposta (evaluator.py)

GUARDRAIL

Guardrail de Saída → Pydantic valida dados de saída
Framework Ollama atua na Etapa 2

OUTPUT

Relatório CSV + Gráficos
Resultados estruturados e visualizações de análise de reviews

STACK TÉCNICA

Python 3.10+ (Linguagem principal)

01

Ollama local + gpt-oss:120b (LLM gratuito)

02

tiktoken ≥0.7 (Contagem de tokens)

03

pandas ≥2.2 (Manipulação e CSV)

04

matplotlib ≥3.8 (Gráficos)

05

python-dotenv + requests (Ambiente e API)

06

EVOLUÇÃO DOS SYSTEM PROMPTS

— V1 → V2 → V3

Comparativo das três versões de prompts desenvolvidas, mostrando a evolução desde o baseline inicial até a implementação de persona especializada para análise de reviews de e-commerce brasileiro.



V1 — ZERO-SHOT

Prompt genérico sem persona, instrução direta ao modelo.
Justificativa: estabelecer baseline inicial para comparação de performance.



V2 — FEW-SHOT

3 exemplos rotulados por tarefa incluídos no prompt. Justificativa: melhora precisão sem aumentar complexidade do sistema.



V3 — ROLE PROMPTING

Persona "Analista de CX Sênior", contexto e-commerce brasileiro, tom e formato definidos. Justificativa: melhor consistência e adequação ao domínio.

PADRÕES DE PROMPTING APLICADOS

ZERO-SHOT

Prompt direto sem exemplos. Baseline simples para comparação inicial de desempenho.

FEW-SHOT

3 exemplos rotulados por tarefa. Melhor acurácia em classificação de sentimentos.

CHAIN-OF-THOUGHT

Raciocínio passo a passo. Acurácia em extração NER: 60% → 85% (+25%).

ROLE PROMPTING

Persona especializada + contexto e-commerce brasileiro. Melhor qualidade em sumarização.

ANTES VS DEPOIS

CoT aumentou acurácia de extração em +25%. Role Prompting elevou consistência geral.

RESULTADOS

Few-Shot e CoT combinados oferecem melhor equilíbrio entre precisão e custo computacional.

AVALIAÇÃO DE DESEMPENHO

Comparação de métricas entre técnicas de prompting: Zero-Shot, Few-Shot, CoT e Role Prompting.

85%

Acurácia CoT

60%


Acurácia Zero-Shot

150MS

Tempo Médio CoT

92%

Consistência Role Prompting



Source: AI-generated data. Replace or verify before use.

GUARDRAILS E SEGURANÇA

Prompt Injection

Tentativas de ignorar instruções do sistema.
Mitigação: Validação rigorosa com Pydantic.

JAILBREAK

Tentativas de bypass das restrições de segurança.
Mitigação: Sanitização de inputs maliciosos.

DATA LEAKAGE

Prevenção de vazamento de dados sensíveis. Mitigação: Monitoramento de comportamento anômalo.

CONCLUSÕES E PRÓXIMOS PASSOS

Resultados Alcançados: Pipeline completo de análise de reviews implementado com sucesso utilizando técnicas avançadas de prompting.

Lições Aprendidas: Chain-of-Thought aumentou acurácia de extração de ~60% para ~85%; Role Prompting garantiu consistência superior em sumarização.

Melhorias Futuras: Expansão para análise multimodal, fine-tuning de modelos específicos para português brasileiro, integração com dashboards em tempo real.

Referências: Documentação Ollama, FIAP Prompt Engineering Course Materials

Contato: [Inserir e-mail do grupo]

Obrigado pela atenção!